

به نام خالق رنگین کمان

ستاره باباجانی – 99521109

سوال 1:

• مورد 1:

○ شبکه عصبی کانولوشن: احتمالاً در تشخیص عکس گربه ها و نقاشی ها خوب عمل می کند. CNN ها در ثبت ویژگی ها و الگوهای محلی در تصاویر ماهر هستند. آنها می توانند یاد بگیرند که جزئیات، بافت ها و اشکال ریز دانه ای را که عکس ها را از نقاشی ها متمایز می کند، تشخیص دهند. با این حال، اگر نقاشی ها بسیار واقعی باشند یا اگر عکس ها به شدت سبک شده باشند، CNN ممکن است با مشکل مواجه شود. CNN ها به ویژه برای وظایف طبقه بندی تصاویر موثر هستند. لایه های کانولوشنال می توانند ویژگی های سلسله مراتبی را از تصاویر ورودی، ثبت الگوها و ساختارهایی که مشخصه گربه ها هستند، بیاموزند. این شبکه احتمالاً ویژگی هایی مانند سبیل ها، گوش ها و الگوهای خز را تشخیص می دهد و به آن امکان می دهد پیش بینی های دقیقی انجام دهد. (شبکه بر روی یک مجموعه داده حاوی تصاویر برچسب گذاری شده از گربه ها و غیر گربه ها آموزش داده میشود و با تنظیم پارامتر های داخلی بین آنها تمایز میگذارد.)

○ مکانیسم توجه برای طبقه بندی گربه: مکانیسم‌های توجه برای تمرکز بر بخش‌های خاصی از توالی ورودی، با تأکید بر اطلاعات مرتبط طراحی شده‌اند. در این مورد، یک شبکه مبتنی بر توجه به طور بالقوه می‌تواند در تشخیص ویژگی‌های متمایز عکس‌ها و نقاشی‌های گربه برتری داشته باشد. ممکن است به صورت پویا توجه خود را به مناطق مهم تنظیم کند و به آن اجازه دهد بین این دو دسته بر اساس جزئیات ظریف تمایز قائل شود. مکانیزم‌های توجه می‌توانند به ویژه مفید باشند اگر نقشه‌ها دارای ویژگی‌های متمایزی باشند که برای طبقه بندی بسیار مهم هستند. (مکانیزم‌های توجه با اختصاص وزن‌های بالاتر به مناطق مهم و تاثیرگذار در تشخیص گربه‌ها و غیر گربه‌ها، در تصمیم‌گیری‌های آینده کمک میکنند).

● مورد 2:


○ شبکه عصبی کانولوشن (CNN) برای طبقه بندی انسان: CNNها برای کارهایی که شامل تصاویر هستند مناسب هستند، اما ممکن است در این مورد مشکل داشته باشند. آنها بر روابط فضایی بین پیکسل‌ها متکی هستند و اگر قسمت‌های صورت از هم جدا شوند، ممکن است زمینه کلی چهره از بین برود. (در مواردی که قسمت‌هایی از صورت جابه‌جا شده باشد، CNN ممکن است تصویر را بر اساس سایر ویژگی‌های دست نخورده به عنوان یک

انسان طبقه‌بندی کند.) سی‌ان‌ان‌ها در ثبت الگوهای کل‌نگر مؤثر هستند، بنابراین اگر ویژگی‌های صورت از هم جدا شوند، شبکه ممکن است در تشخیص آنها به‌عنوان چهره‌های انسانی مشکل داشته باشد.

○ مکانیسم توجه برای طبقه‌بندی انسان: مکانیسم‌های توجه می‌تواند در این سناریو سودمند باشد. یک شبکه مبتنی بر توجه با تمرکز پویا بر روی بخش‌های صورت مرتبط و در نظر گرفتن روابط آنها، ممکن است قادر باشد تشخیص دهد که آیا این بخش‌ها به یک چهره انسانی منسجم تعلق دارند یا خیر. توانایی مکانیزم توجه برای وزن کردن انتخابی بخش‌های مختلف ورودی اجازه می‌دهد تا رویکرد انعطاف‌پذیرتری در مدیریت اطلاعات تکه‌تکه یا پراکنده داشته باشد. (در مورد تصویری که ویژگی‌های صورت جابجا شده است، یک شبکه مبتنی بر توجه ممکن است بتواند روابط فضایی تغییر یافته را تشخیص دهد و اهمیت کمتری را به مناطق دستکاری شده اختصاص دهد. این به‌طور بالقوه می‌تواند منجر به طبقه‌بندی دقیق‌تری به‌عنوان نادرست شود.)

سوال 2: الف) برای ارزیابی عملکرد یک مدل طبقه‌بندی باینری استفاده میشوند، بطوریکه:

1. True Positive (TP): این زمانی اتفاق می افتد که مدل به درستی موارد مثبت را مثبت پیش بینی کند. به عبارت دیگر، مدل به درستی نمونه هایی را که متعلق به کلاس مثبت هستند شناسایی می کند.
 2. True Negative (TN): این زمانی اتفاق می افتد که مدل به درستی موارد منفی را منفی پیش بینی کند. مدل به درستی نمونه هایی را که به کلاس مثبت تعلق ندارند شناسایی می کند.
 3. مثبت کاذب (FP): این زمانی اتفاق می افتد که مدل به اشتباه موارد منفی را مثبت پیش بینی کند. مدل به اشتباه موارد را به عنوان متعلق به کلاس مثبت شناسایی می کند در حالی که این موارد را ندارند.
 4. منفی کاذب (FN): این زمانی اتفاق می افتد که مدل به اشتباه موارد مثبت را منفی پیش بینی کند. این مدل نمی تواند نمونه هایی را که در واقع به کلاس مثبت تعلق دارند شناسایی کند.
- این معیارها برای محاسبه معیارهای مختلف عملکرد، مانند دقت، precision، recall و F1-score استفاده می شوند که ارزیابی جامع تری از اثربخشی یک مدل طبقه بندی در جنبه های مختلف ارائه می دهند.



ب) در زمینه شناسایی عاملان هک اسنپ فود، نمی توان اهمیت ملاحظات اخلاقی را نادیده گرفت. بسیار مهم است که بین نیاز به دقت در شناسایی مجرمان واقعی با الزام اخلاقی اجتناب از اتهامات نادرست علیه افراد بی گناه تعادل برقرار شود. در اینجا نحوه نقش هر معیار ارزیابی در این سناریو شرح داده شده است:

1. Precision: دقت، نسبت پیش بینی های مثبت واقعی به کل پیش بینی های مثبت $(TP / (TP + FP))$ است. دقت بالا به این معنی است که وقتی مدل فردی را به عنوان مجرم شناسایی می کند، احتمالاً درست است.

در سناریوی حساسی مانند شناسایی هکرها، دقت بالا برای به حداقل رساندن اتهامات نادرست و اطمینان از اینکه افراد شناسایی شده احتمالاً مرتکب واقعی هستند، مهم است.

2. Recall: یادآوری (حساسیت یا نرخ مثبت واقعی) نسبت پیش بینی های مثبت واقعی به کل مثبت های واقعی است $(TP / (TP + FN))$. یادآوری زیاد به این معنی است که مدل در دستگیری بیشتر مجرمان واقعی موثر است.

در زمینه تحقیقات جنایی، یادآوری بالا برای اطمینان از شناسایی هر چه بیشتر مجرمان واقعی بسیار مهم است. با این حال، این باید با دقت متعادل شود تا از اتهامات نادرست جلوگیری شود.

3. F1-Score: امتیاز F1 میانگین هارمونیک دقت و فراخوانی است که تعادلی بین این دو ایجاد می کند $(2 * (دقت * یادآوری) / (دقت + یادآوری))$. امتیاز F1 مخصوصاً زمانی مفید است که توزیع کلاس ناهموار وجود دارد یا زمانی که دقت و یادآوری هر دو مهم هستند.

با در نظر گرفتن هر دو مثبت کاذب و منفی کاذب یک ارزیابی جامع ارائه می دهد. در تحقیقات جنایی، متعادل کردن دقت و یادآوری ضروری است و امتیاز F1 به دستیابی به این تعادل کمک می کند.

4. Accuracy: دقت نسبت نمونه های به درستی پیش بینی شده به کل نمونه ها $(TP + TN) / (TP + TN + FP + FN)$ است. دقت اندازه گیری کلی از پیش بینی های صحیح را فراهم می کند.

در حالی که دقت مهم است، ممکن است تنها معیار نباشد، به خصوص در موقعیت هایی با توزیع طبقاتی نامتعادل (که ممکن است تعداد مرتکبین به طور قابل توجهی کمتر از افراد غیر مرتکب باشد). این می تواند تحت تأثیر تعداد زیادی از منفی های واقعی باشد، که ممکن است نگرانی اصلی در تحقیقات جنایی نباشد.

5. ملاحظات اخلاقی: ملاحظات اخلاقی در هر تحقیق جنایی از اهمیت بالایی برخوردار است و آنها باید توسعه، استقرار و ارزیابی مدل را هدایت کنند. پیامدهای اخلاقی اتهامات نادرست می تواند عواقب شدیدی برای افراد بی گناه داشته باشد. ایجاد تعادل بین معیارهای عملکرد مدل و آسیب احتمالی برای افراد بی گناه ضروری است. انصاف، شفافیت و پاسخگویی جنبه های حیاتی استفاده اخلاقی از هوش مصنوعی در اجرای قانون است.

به طور خلاصه، یک استراتژی ارزیابی جامع در زمینه شناسایی عاملان هک اسنپ فود باید تعادل بین دقت و یادآوری را با اولویت ملاحظات اخلاقی در اولویت قرار دهد. امتیاز F1 معیار مفیدی را ارائه می دهد که هم دقت و هم یادآوری را ترکیب می کند و ارزیابی جامعی از عملکرد مدل ارائه می دهد. علاوه بر این، ملاحظات اخلاقی باید فرآیند تصمیم گیری را هدایت کند تا اطمینان حاصل شود که استقرار مدل با استانداردهای قانونی و اخلاقی مطابقت دارد و خطر اتهامات نادرست را به حداقل می رساند و از حقوق افراد محافظت می کند.

سوال 3: الف) فواید تخمین چرخش برای مسائل طبقه بندی به شرح زیر است:

- افزایش داده ها: آموزش یک مدل بر روی مجموعه متنوعی از تصاویر چرخانده می تواند قابلیت های تعمیم آن را افزایش دهد. با معرفی نسخه های چرخانده شده از تصاویر اصلی در طول آموزش، مدل نسبت به تغییرات جهت گیری قوی تر می شود، که می تواند به ویژه در هنگام برخورد با سناریوهای دنیای واقعی که ممکن است اشیاء همیشه کاملاً در یک راستا قرار نگیرند مفید باشد.
- تعمیم بهبود میابد: تخمین چرخش به مدل کمک می کند تا ویژگی هایی را بیاموزد که نسبت به چرخش ثابت هستند. این می تواند به تعمیم بهتر منجر شود، زیرا مدل نسبت به تغییرات جهت گیری حساسیت کمتری دارد و احتمال دارد اشیاء را بدون توجه به زوایای چرخش آنها تشخیص دهد.
- تغییر پذیری: در برخی از کاربردها، جهت گیری یک شی ممکن است یک عامل حیاتی برای طبقه بندی باشد. به عنوان مثال، در تصویربرداری پزشکی، جهت گیری صحیح یک عضو یا ناهنجاری ممکن است برای تشخیص بسیار مهم باشد. تخمین چرخش می تواند به مدل در طبقه بندی صحیح اشیاء بر اساس جهت آنها کمک کند.
- پرداختن به سناریوهای دنیای واقعی: در سناریوهای دنیای واقعی، اشیاء ممکن است در جهت گیری های مختلف به دلیل نحوه ثبت آنها توسط

دوربین‌ها یا حسگرها ظاهر شوند. داشتن مدلی که بتواند جهت گیری های مختلف را مدیریت کند، آن را برای کاربردهای دنیای واقعی که جهت گیری اشیا ممکن است متفاوت باشد، کاربرد بیشتری دارد.

- کاهش بار حاشیه نویسی: به جای حاشیه نویسی دستی تصاویر در جهت گیری های متعدد، تخمین چرخش می تواند فرآیند را خودکار کند. با آموزش یک مدل برای تخمین زاویه چرخش یک شی، می توانید بار حاشیه نویسی را کاهش دهیم و فرآیند آموزش را کارآمدتر کنیم.

- تشخیص شی و محلی سازی: در کارهایی که شامل تشخیص و مکان‌یابی شیء است، تخمین دقیق چرخش یک جسم می‌تواند به اصلاح مختصات جعبه مرزی کمک کند. این اطلاعات می‌تواند برای برنامه هایی مانند وسایل نقلیه خودران یا روباتیک بسیار مهم باشد.

به طور خلاصه، گنجاندن تخمین چرخش در یک کار طبقه‌بندی یادگیری عمیق می‌تواند به مدل‌های قوی‌تری منجر شود که به خوبی به جهت‌گیری‌های مختلف تعمیم می‌یابند و در نهایت عملکرد را در برنامه‌های کاربردی دنیای واقعی با شرایط متفاوت بهبود می‌بخشند.

ب) این بردار یک نمایش برداری باینری است که معمولاً در یادگیری ماشین و یادگیری عمیق برای رمزگذاری متغیرهای طبقه‌بندی استفاده می‌شود. این روشی برای نمایش مقادیر گسسته به عنوان بردارهای مقادیر باینری است، که

در آن تنها یک عنصر در بردار "گرم" است (تنظیم شده روی 1)، در حالی که همه عناصر دیگر "سرد" هستند (0 تنظیم شده است). موقعیت عنصر "hot" نشان دهنده دسته یا کلاسی است که متغیر به آن تعلق دارد. مشکلات استفاده از one-hot vectors به شرح زیر است:

- بعد بالا: رمزگذاری one-hot، ابعاد داده ها را افزایش می دهد، به ویژه هنگامی که با تعداد زیادی دسته سروکار داریم. این می تواند منجر به نمایش پراکنده شود و داده ها را برای ذخیره و پردازش ناکارآمد کند.
- عدم اطلاعات معنایی: بردارهای one-hot دسته ها را به عنوان موجودیت های نامرتبط در نظر می گیرند، و هیچ گونه رابطه معنایی یا شباهتی بین دسته ها را نشان نمی دهند. برای مثال، فاصله اقلیدسی بین هر دو بردار one-hot، صرف نظر از شباهت معنایی واقعی بین مقوله های مربوطه، همیشه یکسان است.
- قابلیت تفسیر مدل: برای مدل هایی که بر تعبیه ها یا نمایش های متراکم متکی هستند، بردارهای one-hot ممکن است اطلاعات معنی داری درباره روابط بین دسته های مختلف ارائه نکنند. تعبیه ها اغلب روابط معنایی را در بر می گیرند که در رمزگذاری یک طرف وجود ندارد.
- Curse of Dimensionality: ابعاد بالای معرفی شده توسط curse of dimensionality رمزگذاری one-hot می تواند به کمک کند، به خصوص در شرایطی که تعداد دسته ها زیاد است. این می

تواند منجر به افزایش پیچیدگی محاسباتی و نیاز به مجموعه داده های بزرگتر شود.

- کنترل نکردن دسته های ناشناخته: رمزگذاری one-hot فرض می کند که همه دسته ها در طول آموزش شناخته شده اند. اگر مدلی در حین آزمایش با مقوله ای مواجه شود که در مجموعه آموزشی وجود نداشت، ممکن است برای مدیریت آن مشکل داشته باشد، زیرا بردار یک داغ مربوطه در طول آموزش یاد نگرفته است.
- مشکل در مدیریت داده های متوالی: برای کارهایی که شامل دنباله ها هستند، مانند پردازش زبان طبیعی، رمزگذاری یک طرفه ممکن است روابط متوالی بین دسته ها را نشان ندهد. فاقد توانایی نمایش نظم یا وابستگی بین مراحل مختلف زمانی است.

ج) Word2Vec با تعریف الگوریتم های خود نظارت مطابقت دارد زیرا روشی برای آموزش جاسازی کلمات از داده های متنی بدون برچسب است. در یادگیری خود نظارتی، الگوریتم، سیگنال نظارتی خود را از داده های ورودی بدون تکیه بر برچسب های ارائه شده خارجی تولید می کند. Word2Vec با فرمول بندی وظیفه ای که ذاتاً با ساختار داده های ورودی مرتبط است به این امر دست می یابد.

در اینجا نحوه سازگاری Word2Vec در الگوی یادگیری خود نظارتی آمده است:

- تشکیل وظیفه: Word2Vec کار تحت نظارت خود را بر اساس زمینه ای که در آن کلمات در یک پیکره مشخص ظاهر می شوند، معرفی می کند. از یک پنجره کشویی برای در نظر گرفتن کلمات اطراف (زمینه) برای هر کلمه هدف در یک جمله استفاده می کند. الگوریتم دو کار را فرموله می کند: کیسه کلمات پیوسته (CBOW) و Skip-Gram.
- کیف کلمات پیوسته (CBOW): در CBOW، وظیفه پیش بینی کلمه هدف (کلمه مرکزی) با توجه به کلمات بافت اطراف آن است. این مدل برای یادگیری توزیع احتمال کلمات هدف با توجه به کلمات متن آنها آموزش داده شده است.
- Skip-Gram: در Skip-Gram، کار برعکس است. این مدل برای پیش‌بینی کلمات متنی بر اساس کلمه هدف آموزش داده شده است. هدف، به حداکثر رساندن احتمال کلمات متنی با توجه به کلمه هدف است.
- عملکرد هدف: Word2Vec از شکلی از احتمال ورود منفی به عنوان تابع هدف استفاده می کند. این مدل آموزش داده شده است تا احتمال کلمات بافت مشاهده شده را به حداکثر برساند در حالی که احتمال کلمات نمونه برداری تصادفی که در متن ظاهر نمی شوند را به حداقل می رساند.
- آموزش جاسازی کلمه: همانطور که مدل پارامترهای خود را برای انجام کار پیش بینی زمینه بهینه می کند، اتفاقاً نمایش های برداری پیوسته

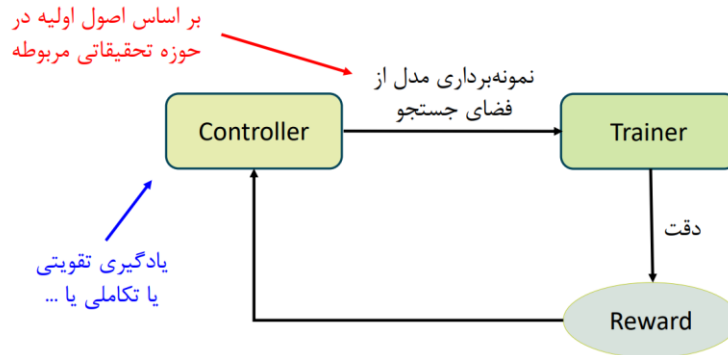
(جاسازی ها) برای هر کلمه را می آموزد. این تعبیه ها روابط معنایی و شباهت های بین کلمات را بر اساس الگوهای همزمانی آنها در داده های آموزشی به تصویر می کشند.

- آموزش بدون نظارت: Word2Vec برای کلمات یا جملات خاص به برچسب های حاشیه نویسی دستی نیاز ندارد. از ساختار و الگوهای ذاتی در داده های متنی بدون برچسب برای ایجاد جاسازی های کلمه معنادار استفاده می کند.

به طور خلاصه، Word2Vec یک الگوریتم خود نظارت است زیرا وظیفه یادگیری را به گونه ای چارچوب بندی می کند که بر ساختار ذاتی خود داده ها متکی است. الگوریتم سیگنال نظارتی خود را با استفاده از روابط بین کلمات در غیاب داده های مشخص شده با برچسب انسانی تولید می کند. این یک ویژگی کلیدی یادگیری خود نظارت است که در آن الگوریتم یادگیری سیگنال های آموزشی خود را از داده های ورودی ایجاد می کند.

سوال 4: الف)

جستجوی معماری عصبی (Neural Architecture Search)



استفاده از RL در NAS شامل مراحل زیر است که در لینک ارائه شده توضیح داده شده است:

1) تعریف فضای جستجو: یک فضای جستجو را تعریف میشود که شامل انواع معماری شبکه عصبی ممکن است. این فضا شامل انتخاب هایی مانند تعداد لایه ها، انواع لایه ها، الگوهای اتصال و سایر تصمیمات معماری است.

2) راه اندازی عامل و محیط: فرآیند ساخت و ارزیابی معماری شبکه های عصبی را به عنوان یک مشکل تصمیم گیری متوالی در نظر میگیریم. عامل، در این مورد، مسئول انتخاب و پیکربندی اجزای معماری است و محیط بازخورد عملکرد معماری را ارائه می دهد.

3) State representation: هر معماری شبکه عصبی نامزد را به عنوان یک حالت در چارچوب RL نشان میدهد. این نمایش باید اطلاعات

مربوط به معماری فعلی، مانند انواع و پیکربندی لایه‌ها را به تصویر بکشد.

4) انتخاب اقدام: عامل RL اقداماتی را برای تغییر معماری فعلی انتخاب می‌کند. اقدامات می‌تواند شامل افزودن یا حذف لایه‌ها، تغییر انواع لایه‌ها، تنظیم هایپرپارامترها و غیره باشد.

5) طراحی پاداش: یک سیگنال پاداش برای تعیین کمیت عملکرد معماری شبکه عصبی تعریف می‌کنیم. این پاداش معمولاً بر اساس دقت مدل یا سایر معیارهای مرتبط است. هدف، به حداکثر رساندن پاداش تجمعی مورد انتظار در طول زمان است.

6) آموزش و ارزشیابی: آموزش و ارزیابی معماری شبکه عصبی تولید شده توسط عامل RL. فرآیند آموزش شامل بهینه‌سازی پارامترهای مدل بر اساس مجموعه داده آموزشی است و ارزیابی عملکرد مدل را بر روی مجموعه اعتبارسنجی ارزیابی می‌کند.

7) به روز رسانی خط مشی: از چارچوب RL برای به روز رسانی خط مشی (استراتژی یا مکانیسم تصمیم‌گیری) عامل بر اساس پاداش‌های به دست آمده استفاده می‌کنیم. این شامل الگوریتم‌های یادگیری تقویتی است، مانند بهینه‌سازی سیاست پروگرمال (PPO) یا بهینه‌سازی خط مشی منطقه اعتماد (TRPO).

8) جستجوی تکراری: فرآیند را برای تکرارهای متعدد تکرار می‌کنیم که به عامل RL اجازه می‌دهد تا فضای جستجو را کاوش کرده و از آن بهره

بررداری کند، و به تدریج به سمت معماری های عصبی که عملکرد خوبی از خود نشان می دهند، همگرا شود.

ایده کلیدی این است که عوامل RL یاد بگیرند که با کاوش و بهره‌برداری مکرر از انتخاب‌های معماری، فضای جستجو را به طور کارآمد هدایت کنند. این روش فرآیند طراحی معماری عصبی را خودکار می کند، نیاز به مداخله دستی را کاهش می دهد و به طور بالقوه معماری های جدید و موثر را برای کارهای خاص کشف می کند.

ب) جستجوی معماری عصبی (NAS) می تواند یک رویکرد قدرتمند برای بهینه سازی هایپرپارامترها، از جمله اندازه تصویر ورودی و تعداد لایه ها در یک شبکه عصبی، به ویژه در زمینه مشکلات تشخیص اشیا باشد. غلت اینکه NAS می تواند برای تعیین این پارامترها مفید باشد به شرح زیر است:

• اندازه تصویر ورودی:

○ جستجوی Scale Invariance: وظایف تشخیص شی مختلف

ممکن است از وضوح ورودی متفاوت بهره مند شوند. به عنوان مثال، اشیاء کوچک ممکن است برای تشخیص دقیق به وضوح بالاتری نیاز داشته باشند. با استفاده از NAS، مدل را می توان برای عدم تغییر مقیاس بهینه کرد و اندازه تصویر ورودی را با ویژگی های خاص کار تطبیق داد.

- استفاده کارآمد از منابع: جستجو برای اندازه تصویر ورودی بهینه تضمین می کند که منابع محاسباتی به طور موثر مورد استفاده قرار می گیرند. وضوح های کوچک تر می توانند منجر به آموزش سریع تر و زمان های استنتاج شوند، در حالی که وضوح های بزرگ تر ممکن است جزئیات بیشتری را به قیمت افزایش محاسبات ثبت کنند. NAS به ایجاد تعادل بر اساس نیازهای کار کمک می کند.
- سازگاری با مجموعه داده های متنوع: مجموعه داده های تشخیص شی ممکن است از نظر اندازه و ویژگی های اشیا متفاوت باشد. NAS می تواند اندازه ورودی را با مجموعه داده های مختلف تطبیق دهد و اطمینان حاصل کند که مدل برای مدیریت انواع سناریوهای ورودی مناسب است.
- تعداد لایه ها:

○ تطبیق ظرفیت: تعداد بهینه لایه ها در یک شبکه عصبی به پیچیدگی الگوهای زیربنایی در داده ها بستگی دارد. لایه های بسیار کم ممکن است منجر به عدم تناسب شوند، در حالی که لایه های بیش از حد ممکن است منجر به برآزش بیش از حد شود. NAS می تواند ظرفیت شبکه را با جستجوی تعداد بهینه لایه ها تطبیق دهد و بین پیچیدگی مدل و تعمیم تعادل ایجاد کند.

○ معماری های خاص وظیفه: وظایف مختلف تشخیص شی ممکن است به معماری های متفاوتی نیاز داشته باشند. به عنوان مثال، معماری های ساده تر ممکن است برای طبقه بندی اشیاء اولیه کافی باشد، در حالی که معماری های پیچیده تر با لایه های اضافی ممکن است برای شناسایی یا شناسایی دقیق تر ضروری باشند.

○ کارایی منابع: تعداد لایه ها به طور مستقیم بر منابع محاسباتی مورد نیاز برای آموزش و استنتاج تأثیر می گذارد. NAS می تواند به یافتن معماری هایی کمک کند که به یک مبادله خوب بین عملکرد مدل و کارایی منابع دست یابند.

○ قابلیت انتقال: NAS می تواند معماری هایی را که قابل انتقال در بین وظایف هستند کشف کند. با یادگیری تنظیمات لایه بهینه، مدل های حاصل ممکن است به خوبی به مجموعه داده ها یا وظایف جدید تعمیم دهند.

به طور خلاصه، استفاده از NAS برای تعیین اندازه تصویر ورودی و تعداد لایه های شبکه های عصبی برای مشکلات تشخیص اشیا سودمند است زیرا امکان انطباق خودکار با الزامات خاص کار، استفاده کارآمد از منابع و کشف معماری هایی که به خوبی در سناریوهای مختلف تعمیم می یابند. این رویکرد از قدرت الگوریتم های جستجوی خودکار برای کشف طیف گسترده ای از احتمالات و یافتن تنظیماتی که منجر به بهبود عملکرد مدل می شود، استفاده می کند.

سوال 5: مقادیر تلفات Generator و Critic در یک GAN اطلاعاتی را در مورد پیشرفت آموزش و تعادل بین مولد و تمایز ارائه می دهد. با این حال، این مقادیر از دست دادن، ممکن است به تنهایی به طور کامل کیفیت تصاویر تولید شده را ثبت نکنند. دلایل متعددی وجود دارد که چرا کیفیت تصاویر تولید شده ممکن است متفاوت باشد، حتی زمانی که مقادیر تلفات در دوره اول و 100 مشابه است:

- **Model Collapse:** فروپاشی حالت زمانی اتفاق می افتد که ژنراتور مجموعه محدودی از نمونه های متنوع یا حتی نمونه های یکسان را تولید کند و متمایزکننده را فریب دهد. مقادیر تلفات ممکن است لزوماً تنوع یا کیفیت تصاویر تولید شده را منعکس نکنند. حتی با مقادیر تلفات مشابه، فروپاشی حالت می تواند منجر به عدم تنوع در نمونه های تولید شده شود.
- **همگرایی به حداقل محلی:** آموزش GAN حساس است و چشم انداز بهینه سازی ممکن است مدل را به حداقل محلی همگرا کند. کیفیت تصاویر تولید شده می تواند تحت تأثیر مسیر خاصی که فرایند بهینه سازی طی می کند، باشد و ممکن است به تنهایی در مقادیر تلفات دقیق منعکس نشود.

- دینامیک آموزش: پویایی آموزشی GAN ها می تواند پیچیده باشد. در دوره های اولیه، مولد و تمایزکننده ممکن است در حال یادگیری جنبه های مختلف توزیع داده باشند. با پیشرفت آموزش، پویایی بین دو شبکه می تواند تغییر کند و بر کیفیت نمونه های تولید شده تأثیر بگذارد.
- حساسیت فرارامتر: آموزش GAN به فرارامترهایی مانند نرخ یادگیری، انتخاب های معماری و اندازه های دسته ای بسیار حساس است. حتی با مقادیر تلفات مشابه، تغییرات کوچک در هایپرپارامترها می تواند منجر به تفاوت در کیفیت تصاویر تولید شده شود.
- نرخ یادگیری ژنراتور: نرخ یادگیری مولد ممکن است بر سرعت انطباق آن با بازخوردهای ممیزکننده تأثیر بگذارد. نرخ بالای یادگیری ممکن است منجر به تغییرات سریع در پارامترهای ژنراتور شود که منجر به نوسانات کیفیت تصویر بین دوره ها می شود.
- اشباع تمایزکننده: اگر تمایزکننده اشباع شود (به پیش بینی های خود بیش از حد مطمئن شود)، ممکن است بازخورد مفید کمتری به مولد ارائه دهد و بر کیفیت نمونه های تولید شده تأثیر بگذارد. این اشباع ممکن است در مراحل مختلف تمرین به طور متفاوتی اتفاق بیفتد.
- **GAN: Stochasticity in Training** ها شامل فرآیندهای تصادفی هستند و آموزش می تواند تصادفی باشد. تغییرات در وزن های تصادفی اولیه، ترتیب نمونه های آموزشی یا ورودی های نویز تصادفی می تواند منجر به تفاوت در نمونه های تولید شده شود.

به طور خلاصه، در حالی که مقادیر تلفات نشان دهنده پیشرفت آموزش خصمانه است، ممکن است تمام جنبه های پویایی آموزش GAN را در بر نگیرد. تفاوت در کیفیت تصاویر تولید شده بین دوره اول و 100 می تواند به دلیل مسائلی مانند فروپاشی حالت، حداقل های محلی، تغییرات در دینامیک آموزش و حساسیت GAN ها به فرآپارامترها ایجاد شود. نظارت بر معیارهای اضافی و بازرسی نمونه های تولید شده به صورت بصری می تواند درک جامع تری از عملکرد مدل ارائه دهد.

پایان